


تمرین سر 2 درس یادگیری عمیق - رادین ختام - 99/1579

سوال 1-

در ابتدا برای اثبات محدب بودن:

\hat{y}_n نگران

$$E_{w,b} = - \sum_n y_n \ln \hat{y}(x_n) + (1 - y_n) \ln (1 - \hat{y}(x_n))$$

$$\hat{y}_n = \frac{1}{1 + e^{-(w^T x_n + b)}} \rightarrow \frac{\partial \hat{y}_n}{\partial w} = \hat{y}_n (1 - \hat{y}_n) x_n$$

$$\rightarrow \frac{\partial \hat{y}_n}{\partial b} = \hat{y}_n (1 - \hat{y}_n)$$

$$\frac{\partial E_{w,b}}{\partial w} = \sum_n \left(\frac{1 - y_n}{1 - \hat{y}_n} - \frac{y_n}{\hat{y}_n} \right) \frac{\partial \hat{y}_n}{\partial w} = \sum_n (\hat{y}_n - y_n) x_n$$

$$\frac{\partial^2 E_{w,b}}{\partial w \partial w^T} = \sum_n \frac{\partial}{\partial w} ((\hat{y}_n - y_n) x_n) = \sum_n \underbrace{\hat{y}_n (1 - \hat{y}_n)}_{\text{همیشه مثبت}} \underbrace{x_n x_n^T}_{\text{PSD}}$$

بنابراین ماتریس هسین PSD است و در نتیجه $E_{w,b}$ محدب است.

$$\frac{\partial E_{w,b}}{\partial b} = \sum_n \left(\frac{1 - y_n}{1 - \hat{y}_n} - \frac{y_n}{\hat{y}_n} \right) \frac{\partial \hat{y}_n}{\partial b} = \hat{y}_n - y_n$$

ادامه سوال 1-

$$\frac{\partial^2 E_{w,b}}{\partial b^2} = \sum_n \frac{\partial}{\partial b} (y_n - \hat{y}_n) = \sum_n \hat{y}_n (1 - \hat{y}_n)$$

همیشه مثبت

بنابراین ماتریس هسین PSD است و تابع محدب است.

حال چون می‌دانیم که $E_{w,b}$ یک مینیمم گلوبال دارد پس بهین شکل می‌توانیم w و b را در آن نقطه به دست آوریم:

$$w_{n+1} = w_n - \eta_1 \sum_n (\hat{y}_n - y_n) x_n$$

$$b_{n+1} = b_n - \eta_2 \sum_n (\hat{y}_n - y_n)$$

سوال 2-

الف) Covariate Shift به پدیده‌ای می‌گویند که در آن توزیع داده‌های ورودی یک شبکه عصبی در هنگام آموزش تغییر نکند و باعث سخت‌تر شدن یادگیری می‌شود. در شبکه‌های عصبی خروجی هر لایه ورودی لایه بعد است و زمانی که وزن‌های هر لایه آپدیت می‌شوند، توزیع ورودی به هر یک از لایه‌های بعدی تغییر می‌کند. این پدیده سرعت آموزش را کاهش می‌دهد چون شبکه باید هوش خودش را توزیع متغیر داده‌ها مطابق کند.

ادله سؤال 2 الف)

BN برای هر مینی بچ میانگین و واریانس داده‌های ورودی به لایه را محاسبه می‌کند و آن را به گودان نرمالایز می‌کند که میانگین صفر و واریانس واحد داشته باشند. به این ترتیب سعی می‌کند که توزیع داده‌ها بهم نرسند. همچنین بعد از اینکه به میانگین صفر و واریانس واحد رسیدند، BN پارامترهای قابل آموزش برای شیف و اسکیل در نظر می‌گیرد تا اثر میانگین صفر و واریانس واحد مناسب نبود مدل بتواند آن را تغییر بدهد.

(ب)

همین کاهش Covariate shift می‌تواند به جنرالیزیشن شبیه کمک کند. BN اثراتی مشابه با بقیه روش‌های رگرسیون مثل L_2 و dropout دارد و برای همین می‌توانیم آن‌ها را از شبکه حذف کنیم تا مدل ساده‌تر شود. همچنین می‌توانیم از رفرنس ریت بالاتر استفاده کنیم. در نهایت می‌توان گفت که BN مسیر آپتیمیزیشن را نرم‌تر می‌کند که این می‌تواند به جنرالایز شدن مدل کمک کند.

(پ)

$$\mu = \frac{1}{n} \sum_{j=1}^n x_j$$

$$\hat{x}_i = x_i - \mu = x_i - \frac{1}{n} \sum_{j=1}^n x_j$$

$$L = \sum_{j=1}^n L_j$$

ادامه سوال 2 ب)

$$\rightarrow \frac{\partial \hat{x}_i}{\partial x_j} = \begin{cases} 1 - \frac{1}{n}, & i=j \\ -\frac{1}{n}, & i \neq j \end{cases}, \quad \begin{cases} y_i = \gamma \hat{x}_i + \beta \\ \rightarrow \frac{\partial L}{\partial \hat{x}_i} = \gamma \frac{\partial L}{\partial y_i} \end{cases}$$

$$\begin{aligned} \frac{\partial L}{\partial x_i} &= \sum_{j=1}^n \frac{\partial L}{\partial \hat{x}_j} \times \frac{\partial \hat{x}_j}{\partial x_i} = -\frac{1}{n} \left(\sum_{j=1}^n \frac{\partial L}{\partial \hat{x}_j} \right) + \frac{\partial L}{\partial \hat{x}_i} \\ &= \gamma \left(\frac{\partial L}{\partial y_i} - \frac{1}{n} \sum_{j=1}^n \frac{\partial L}{\partial y_j} \right) \end{aligned}$$

نتیجه

$$n=1: \quad \mu = x_1 \rightarrow \hat{x}_1 = x_1 - x_1 = 0 \rightarrow \frac{\partial y_1}{\partial \hat{x}_1} = 0$$

$$\rightarrow \frac{\partial L}{\partial x_1} = 0$$

$$n \rightarrow \infty:$$

در این حالت تأثیر هر x_i بر μ بسیار اندک است $\rightarrow \frac{\partial \mu}{\partial x_i} = 0$

$$\rightarrow \frac{\partial \hat{x}_i}{\partial x_j} \begin{cases} 1, & i=j \\ 0, & i \neq j \end{cases} \rightarrow \frac{\partial L}{\partial x_i} = \gamma \frac{\partial L}{\partial y_i}$$

* نتیجه گرفته می شود که اگر n خیلی بزرگ شود اثر نرمالایزیسیون از بین می رود.

سؤال 3 -
الف)

$$\hat{y}_k = \text{softmax}(z^{(2)}) = \frac{e^{z_k^{(2)}}}{\sum_{j=1}^K e^{z_j^{(2)}}}$$

$$\frac{\partial \hat{y}_k}{\partial z_i^{(2)}} = \frac{\frac{\partial e^{z_k^{(2)}}}{\partial z_i^{(2)}} \sum_{j=1}^K e^{z_j^{(2)}} - \left(\sum_{j=1}^K \frac{\partial e^{z_j^{(2)}}}{\partial z_i^{(2)}} \right) \times e^{z_k^{(2)}}}{\left(\sum_{j=1}^K e^{z_j^{(2)}} \right)^2}$$

$$i=k: \quad \frac{\partial \hat{y}_k}{\partial z_k^{(2)}} = \frac{e^{z_k^{(2)}} \sum_{j=1}^K e^{z_j^{(2)}} - (e^{z_k^{(2)}})^2}{\left(\sum_{j=1}^K e^{z_j^{(2)}} \right)^2} = \hat{y}_k (1 - \hat{y}_k)$$

$$i \neq k: \quad \frac{\partial \hat{y}_k}{\partial z_i^{(2)}} = \frac{-e^{z_k^{(2)}} e^{z_i^{(2)}}}{\left(\sum_{j=1}^K e^{z_j^{(2)}} \right)^2} = -\hat{y}_k \hat{y}_i$$

ب)

$$L = - \sum_{i=1}^K y_i \log(\hat{y}_i) = - \log(\hat{y}_k)$$

$$\rightarrow \frac{\partial L}{\partial z_i^{(2)}} = \frac{\partial L}{\partial \hat{y}_i} \frac{\partial \hat{y}_i}{\partial z_i^{(2)}}$$

$$\frac{\partial L}{\partial z_i^{(2)}} = \hat{y}_i - y_i$$

$$\frac{\partial L}{\partial \hat{y}_i} = \begin{cases} \frac{-1}{\hat{y}_k}, & i=k \\ 0, & i \neq k \end{cases}$$

$$\rightarrow \frac{\partial L}{\partial z_i^{(2)}} = \begin{cases} \hat{y}_k - 1 & i=k \\ \hat{y}_i & i \neq k \end{cases}$$

(ب)

$$\frac{\partial L}{\partial z^{(2)}} = \hat{y} - y$$

$$\frac{\partial z^{(2)}}{\partial a^{(1)}} = (w^{(2)})^T, \quad \frac{\partial a^{(1)}}{\partial \hat{a}^{(1)}} = \begin{cases} 1, & p = 0.8 \\ 0, & p = 0.2 \end{cases}$$

$$\frac{\partial \hat{a}^{(1)}}{\partial z_i^{(1)}} = \begin{cases} 1, & z_i^{(1)} > 0 \\ 0.01, & z_i^{(1)} \leq 0 \end{cases}, \quad \frac{\partial z^{(1)}}{\partial w^{(1)}} = x^T$$

$$\rightarrow \frac{\partial L}{\partial w^{(1)}} = \frac{\partial L}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial \hat{a}^{(1)}} \frac{\partial \hat{a}^{(1)}}{\partial z_i^{(1)}} \frac{\partial z^{(1)}}{\partial w^{(1)}}$$

$$\nabla y = \begin{bmatrix} \frac{\partial y}{\partial z} \\ \frac{\partial y}{\partial v} \\ \frac{\partial y}{\partial u} \end{bmatrix} \rightarrow J(\nabla y) = \begin{bmatrix} \frac{\partial^2 y}{\partial u^2} & \frac{\partial^2 y}{\partial u \partial v} & \frac{\partial^2 y}{\partial u \partial z} \\ \frac{\partial^2 y}{\partial v \partial u} & \frac{\partial^2 y}{\partial v^2} & \frac{\partial^2 y}{\partial v \partial z} \\ \frac{\partial^2 y}{\partial z \partial u} & \frac{\partial^2 y}{\partial z \partial v} & \frac{\partial^2 y}{\partial z^2} \end{bmatrix}$$

سؤال 4 -

$$H = \begin{bmatrix} \frac{\partial^2 y}{\partial u^2} & \frac{\partial^2 y}{\partial u \partial v} & \frac{\partial^2 y}{\partial u \partial z} \\ \frac{\partial^2 y}{\partial v \partial u} & \frac{\partial^2 y}{\partial v^2} & \frac{\partial^2 y}{\partial v \partial z} \\ \frac{\partial^2 y}{\partial z \partial u} & \frac{\partial^2 y}{\partial z \partial v} & \frac{\partial^2 y}{\partial z^2} \end{bmatrix}$$

→ هيسس هـ

$$J_1 = \frac{1}{2} \left(y_d - \sum_{k=1}^n \beta_k w_k x_k \right)^2, \quad \beta_k \sim \mathcal{N}(1, \sigma^2)$$

$$\frac{\partial J_1}{\partial w_i} = \frac{1}{2} \frac{\partial}{\partial w_i} \left(y_d - \sum_{k=1}^n \beta_k w_k x_k \right)^2$$

$$= \left(y_d - \sum_{k=1}^n \beta_k w_k x_k \right) \times -\beta_i x_i$$

$$\rightarrow E \left[\frac{\partial J_1}{\partial w_i} \right] = -x_i y_d E[\beta_i] + x_i \sum_{k=1}^n E[\beta_i \beta_k] w_k x_k$$

$$E[\beta_i \beta_k] = \begin{cases} E[\beta_i]^2 + \text{Var}(\beta_i) = 1 + \sigma^2 & i = k \\ E[\beta_i] E[\beta_k] = 1 & i \neq k \end{cases}$$

$$\rightarrow E \left[\frac{\partial J_1}{\partial w_i} \right] = -x_i y_d + x_i \left((1 + \sigma^2) w_i x_i + \sum_{\substack{k=1 \\ k \neq i}}^n w_k x_k \right)$$

$$= -x_i \left(y_d - (1 + \sigma^2) w_i x_i - \sum_{\substack{k=1 \\ k \neq i}}^n w_k x_k \right)$$

ادامه سوال 5 -

non-regularized $\rightarrow \hat{F}_1 = \frac{1}{2} (y_d - \sum_{k=1}^n w_k x_k)^2$

$$\rightarrow \frac{\partial \hat{F}_1}{\partial w_i} = -x_i \times (y_d - w_i x_i - \sum_{\substack{k=1 \\ k \neq i}}^n w_k x_k)$$

یک ترم σ^2 کم شده

مدر واقع ما یک ترم $-\sigma^2 w_i x_i$ به مشتق اضافه کرده ایم و این طاقه این هست که ما به w_i یک ترمینر اضافه کرده ایم.

سوال 6 -

$$e_k = x_k - x^* \rightarrow x^* = x_k - e_k$$

$$f'(x) = f'(x) \rightarrow x_{k+1} = x_k - \frac{f'(x)}{f''(x)} = x_k - \frac{f(x)}{f'(x)}$$

$$f(x^*) = f(x_k - e_k) \simeq f(x_k) - e_k f'(x_k) + \frac{e_k^2}{2} f''(\xi_k)$$

$x_k < \xi_k < x^*$

$$f(x^*) = 0 \rightarrow f(x_k) - e_k f'(x_k) + \frac{e_k^2}{2} f''(\xi_k) = 0$$

اداره سؤال 6 -

$$\rightarrow \frac{f(x_k)}{f'(x_k)} = c_k + \frac{c_k^2}{2f'(x_k)} f''(\xi_k)$$

$$\rightarrow x_k - x_{k-1} = x_k - x^* + \frac{(x_k - x^*)^2}{2f'(x_k)} f''(\xi_k)$$

$$\rightarrow x_{k-1} - x^* = \frac{(x_k - x^*)^2}{2f'(x_k)} f''(\xi_k) \rightarrow |x_{k-1} - x^*| \leq \frac{(x_k - x^*)^2}{2|f'(x_k)|} |f''(\xi_k)|$$

↪ آخر $k \rightarrow \infty$ با توجه به پیوستگی خواص داشت :

$$f'(x_k) \rightarrow f'(x^*), \quad x_k \rightarrow x^*$$

سؤال 7 -

(الت)

$$\frac{\partial}{\partial z_i} L(z, \hat{y}) = \frac{\partial}{\partial z_i} \left(- \sum_{k=1}^K y_k \log \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \right) = \frac{\partial}{\partial z_i} \left(- \sum_{k=1}^K y_k z_i + \sum_{k=1}^K y_k \log \left(\sum_{j=1}^K e^{z_j} \right) \right)$$

$$= - \sum_{k=1}^K y_k + \sum_{k=1}^K y_k \left(\frac{z_i}{\sum_{j=1}^K e^{z_j}} \right) = \hat{y}_i - 1 = \hat{y}_i - y_i$$

$$\rightarrow \nabla_z L(z, \hat{y}) = \hat{y} - y$$

ادامہ نکال دے -

ب)

$$\frac{\partial^2}{\partial z_i^2} L(z, \beta) = \frac{\partial}{\partial z_i} (\hat{y}_i - 1) = \frac{\partial}{\partial z_i} \left(\frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} - 1 \right) = \hat{y}_i (1 - \hat{y}_i)$$

$$\frac{\partial^2}{\partial z_i \partial z_j} L(z, \beta) = \frac{\partial}{\partial z_j} \left(\frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} - 1 \right) = -\hat{y}_i \hat{y}_j$$

$$-\nabla^2 H = \begin{bmatrix} \hat{y}_1(1-\hat{y}_1) & -\hat{y}_1\hat{y}_2 & \dots & -\hat{y}_1\hat{y}_K \\ -\hat{y}_2\hat{y}_1 & \hat{y}_2(1-\hat{y}_2) & \dots & -\hat{y}_2\hat{y}_K \\ \vdots & \vdots & \ddots & \vdots \\ -\hat{y}_K\hat{y}_1 & -\hat{y}_K\hat{y}_2 & \dots & \hat{y}_K(1-\hat{y}_K) \end{bmatrix}$$

$$-\nabla^2 H = \text{diag}(\hat{y}) - \hat{y}\hat{y}^T$$

$$\rightarrow x^T H x = x^T \text{diag}(\hat{y}) x - x^T \hat{y}\hat{y}^T x = \sum_{i=1}^K \hat{y}_i x_i^2 - (\hat{y}^T x)^2$$

$$(\hat{y}^T x)^2 = \left(\sum_{i=1}^K \hat{y}_i x_i \right)^2$$

$$\sum_{i=1}^K \hat{y}_i x_i^2 = \left(\sum_{i=1}^K \hat{y}_i \right) \left(\sum_{i=1}^K \hat{y}_i x_i^2 \right)$$

طبق نامساوی کوشر-شوارتز :

$$\left(\sum_{i=1}^K \hat{y}_i x_i \right)^2 \leq \left(\sum_{i=1}^K \hat{y}_i \right) \left(\sum_{i=1}^K \hat{y}_i x_i^2 \right) \rightarrow \sum_{i=1}^K \hat{y}_i x_i^2 \geq (\hat{y}^T x)^2$$

$$\text{PSD} \quad \text{لہذا} \quad x^T H x \geq 0$$

چون ماتریس Hessian، PSD ہے پس تابع محدب ہے۔